

### 1. Đặt vấn đề

Nhận dạng biểu cảm khuôn mặt (Facial Expression Recognition - FER) là một hướng nghiên cứu quan trọng trong thị giác máy tính, nhưng bài toán hiện nay không còn dừng ở việc phân loại một ảnh mặt sạch vào một số nhãn cảm xúc cơ bản. Trong bối cảnh in-the-wild, biểu cảm thường xuất hiện cùng che khuất, thay đổi góc nhìn, nhiễu ánh sáng, khác biệt định danh, nền cảnh phức tạp và nhãn cảm xúc không hoàn toàn chắc chắn [1]. Những yếu tố này làm cho mô hình dễ học các đặc trưng phụ như identity hoặc background, thay vì tập trung vào chuyển động cơ mặt liên quan trực tiếp tới biểu cảm.

Từ góc nhìn của đề tài này, vấn đề cốt lõi không chỉ là cải thiện độ chính xác phân loại, mà là xây dựng một biểu diễn biểu cảm ổn định và có khả năng diễn giải. Nếu mô hình chỉ học từ nhãn lớp như happy, sad hoặc angry, tín hiệu giám sát có thể quá thô so với bản chất cục bộ và mềm của biểu cảm khuôn mặt. Vì vậy, nghiên cứu này xem xét khả năng sử dụng các mô tả ngữ nghĩa về emotion/AU như các semantic anchors nhằm dẫn hướng visual encoder học đặc trưng biểu cảm có ý nghĩa hơn.

### 2. Các thách thức chính của FER hiện tại

Một thách thức nổi bật của FER in-the-wild là che khuất cục bộ. Các vùng mắt, lông mày và miệng thường chứa nhiều tín hiệu Action Unit (AU), nhưng lại dễ bị che bởi khẩu trang, kính, tóc, tay hoặc vật thể trong cảnh. Khi tín hiệu ở các vùng này bị mất, đặc trưng toàn cục của khuôn mặt có thể không còn đủ tin cậy. Các phương pháp gần đây thường xử lý vấn đề này bằng multi-branch feature, cross-attention hoặc channel-spatial fusion để giảm ảnh hưởng của vùng bị che [2], [3]. Tuy nhiên, các cơ chế này chủ yếu vẫn học đặc trưng thị giác; chúng chưa đảm bảo rằng vùng local được học sẽ tương ứng với một mô tả cơ mặt có thể diễn giải.

Thách thức thứ hai là thay đổi góc nhìn và self-occlusion. Khi khuôn mặt lệch khỏi frontal view, một số vùng biểu cảm có thể bị biến dạng hoặc biến mất khỏi ảnh. Các hướng pose-invariant FER sử dụng local patch attention, multi-scale attention hoặc frontalization để giữ lại thông tin biểu cảm [4], [5]. Một số nghiên cứu về AU cũng khai thác multi-view hoặc multimodal fusion để bổ sung thông tin giữa các góc nhìn [6]. Dù vậy, những hướng này thường làm tăng yêu cầu về dữ liệu, tiền xử lý hoặc thiết bị thu nhận.

Ngoài occlusion và pose, FER còn chịu ảnh hưởng của identity, background, illumination và domain shift. Norface cho thấy chuẩn hóa identity, pose và background có thể giúp mô hình tập trung hơn vào các yếu tố liên quan tới biểu cảm, từ đó cải thiện cả AU detection, AU intensity estimation và FER [7]. Kết quả này củng cố nhận định rằng mô hình FER cần được ràng buộc để giảm phụ thuộc vào các shortcut không liên quan tới biểu cảm. Tuy nhiên, việc thêm một pipeline normalization riêng cũng làm tăng độ phức tạp của hệ thống.

Một vấn đề khác có tính bản chất là sự mơ hồ của nhãn cảm xúc. Cùng một khuôn mặt có thể được gán nhiều nhãn hợp lý, nhất là trong trường hợp biểu cảm nhẹ, compound emotion hoặc ảnh chất lượng thấp. Các hướng uncertainty-aware FER, label distribution learning và auxiliary AU graph chỉ ra rằng mô hình softmax một-nhãn có xu hướng quá tự tin trong các trường hợp mơ hồ [8]-[11]. Do đó, uncertainty nên được xem như một thành phần hiệu chỉnh cần thiết, nhưng chưa đủ để giải quyết câu hỏi biểu diễn ngữ nghĩa của biểu cảm.

| Thách thức FER                       | Hướng xử lý hiện tại                                                   | Giới hạn còn lại                                      | Hàm ý cho đề tài                                                          |
|--------------------------------------|------------------------------------------------------------------------|-------------------------------------------------------|---------------------------------------------------------------------------|
| Che khuất vùng mắt/miệng             | Multi-branch feature, cross-attention, channel-spatial fusion [2], [3] | Đặc trưng local vẫn có thể thiếu ràng buộc ngữ nghĩa. | Cần gắn visual cue với emotion/AU descriptors để tăng khả năng diễn giải. |
| Pose lệch và self-occlusion          | Pose-invariant attention, frontalization, multi-view fusion [4]-[6]    | Yêu cầu thêm tiền xử lý, dữ liệu hoặc thiết bị.       | Cần kết hợp global context với local/AU-aware alignment.                  |
| Identity, background và domain shift | Identity normalization, augmentation, domain generalization [7]        | Pipeline phụ làm tăng độ phức tạp.                    | Semantic anchors có thể giảm phụ thuộc vào shortcut thị giác.             |
| Label ambiguity và overconfidence    | Label distribution, uncertainty learning, auxiliary AU graph [8]-[11]  | Calibration chưa tạo ra semantic representation.      | Uncertainty nên là nhánh phụ sau semantic alignment.                      |

### 3. Vision-language models như nền tảng ngữ nghĩa

Sự phát triển của vision-language models (VLMs), đặc biệt là CLIP, mở ra khả năng đưa tri thức ngôn ngữ vào các bài toán thị giác. Các phương pháp như Tip-Adapter, CoOp, CoCoOp và MaPLe cho thấy không nhất thiết phải huấn luyện lại toàn bộ mô hình; thay vào đó, có thể thích nghi không gian CLIP bằng adapter hoặc prompt learning [12]-[15]. Đối với FER, điểm hấp dẫn của hướng này là text prompt có thể chứa thông tin mô tả biểu cảm, không chỉ đơn thuần là tên lớp.

Trong các nghiên cứu FER/DFER gần đây, CLIPER, DFER-CLIP, FineCLIPER và EA-CLIP đã khai thác mô tả văn bản, temporal modeling hoặc adapter để cải thiện nhận dạng biểu cảm [16]-[19]. Tuy nhiên, nếu chỉ sử dụng prompt dạng class name như a happy face, đóng góp của mô hình có thể chưa khác biệt rõ so với prompt tuning thông thường. Khoảng trống còn lại là làm thế nào để text side mang thông tin chi tiết hơn về vùng mặt, AU và cường độ biểu cảm.

### 4. Kế thừa CLIP-ReID nhưng thay đổi đơn vị anchor

CLIP-ReID là một điểm tham chiếu quan trọng vì mô hình này sử dụng text feature làm anchor để dẫn hướng image encoder trong bối cảnh không có nhãn văn bản cụ thể [20]. Trong bài toán ReID, các token được học theo từng identity giúp mô hình phân biệt người hiệu quả, nhưng các token đó không nhất thiết mang ý nghĩa ngôn ngữ rõ ràng. Các hướng ReID có language guidance như Pedestrian Prompt, CLIP-SCGI và CLIP-driven semantic discovery tiếp tục cho thấy vai trò của ngôn ngữ trong việc ổn định và làm giàu biểu diễn thị giác [21]-[23].

Khi chuyển tư tưởng này sang FER, cần điều chỉnh đơn vị anchor cho phù hợp với bản chất biểu cảm. Nếu ReID quan tâm tới định danh, thì FER quan tâm tới trạng thái cơ mặt, vốn cục bộ, mềm và có thể mơ hồ. Vì vậy, đề tài này không kế thừa ID token của CLIP-ReID một cách trực tiếp, mà kế thừa cơ chế hai giai đoạn dùng text embedding làm anchor. Điểm mới nằm ở việc thay ID-specific tokens bằng emotion/AU semantic descriptors có thể diễn giải.

### 5. AU/FACS như lớp mô tả trung gian

Action Units (AU) và Facial Action Coding System (FACS) cung cấp một lớp mô tả trung gian giữa hình ảnh khuôn mặt và nhãn cảm xúc. Các nghiên cứu như MER-CLIP, VL-FAU, AUFormer và AUNCE cho thấy AU có thể hỗ trợ vision-language alignment, explainable AU recognition hoặc học biểu diễn tương phản cho AU detection [24]-[27]. Điều này phù hợp với mục tiêu của đề tài: thay vì để descriptor chỉ là

happy hoặc sad, descriptor có thể mô tả các cue cụ thể như raised cheeks, lip corner puller, brow lowerer, eye closure hoặc mouth opening.

Tuy nhiên, AU không nên được đặt như một giả định bắt buộc cho mọi tập dữ liệu FER. Nhiều dataset không có AU label, AU annotation có thể nhiễu, và một biểu cảm phức hợp không luôn ánh xạ một-một sang một tập AU cố định. Do đó, cách tiếp cận hợp lý hơn là xem AU/FACS như semantic prior có điều kiện. Phiên bản cơ sở có thể học emotion descriptors; các thí nghiệm mở rộng hoặc ablation có thể kiểm tra AU/pseudo-AU descriptors.

## 6. Định hướng mô hình EmotionCLIP-ReID

Từ các phân tích trên, EmotionCLIP-ReID có thể được định vị như một mô hình image-text FER kế thừa cơ chế anchor của CLIP-ReID nhưng thiết kế lại text side cho biểu cảm. Ở Stage 1, EmotionPromptLearner học các emotion/AU descriptors thông qua CLIP text encoder. Sau đó, descriptor embeddings được cố định như semantic anchors. Ở Stage 2, các anchors này dẫn hướng image encoder học biểu diễn biểu cảm thông qua global image-text alignment và local/AU-aware alignment.

Về kiến trúc, image encoder có thể sử dụng expression-aware adapters hoặc lightweight tuning để thích nghi với FER mà không phá vỡ tri thức nền của CLIP. Global feature giữ thông tin toàn mặt, trong khi local feature hoặc AU-aware tokens tập trung vào các vùng mắt, lông mày, mũi và miệng. Classifier head dự đoán nhãn cảm xúc, còn uncertainty/evidence head có thể được dùng để giảm overconfidence khi ảnh bị che, pose lệch hoặc nhãn mơ hồ.

| Thành phần                               | Vai trò trong mô hình                            | Cơ sở từ related work                                                      | Thí nghiệm cần có                                         |
|------------------------------------------|--------------------------------------------------|----------------------------------------------------------------------------|-----------------------------------------------------------|
| EmotionPromptLearner + CLIP text encoder | Học emotion/AU descriptor embeddings.            | Prompt/adaptation giúp VLM thích nghi với downstream tasks [12]-[15].      | Class-name prompt vs learned descriptor vs AU descriptor. |
| Fixed semantic anchors                   | Ổn định hướng học của image encoder sau Stage 1. | CLIP-ReID dùng text feature làm anchor cho image encoder [20].             | Không anchor vs trainable anchor vs fixed anchor.         |
| Expression-aware adapters                | Thích nghi CLIP visual encoder cho FER.          | CLIPER/FineCLIPER/EA-CLIP cho thấy adapter hữu ích cho FER/DFER [16]-[19]. | Frozen CLIP vs adapter vs full fine-tuning.               |
| Global-local image-text alignment        | Liên kết toàn mặt và vùng local với descriptor.  | Occlusion/pose FER cần local attention và fusion [2]-[6].                  | Global only vs local only vs global-local.                |
| Uncertainty/evidence head                | Giảm dự đoán quá tự tin trong trường hợp mơ hồ.  | Uncertainty-aware FER xử lý ambiguity và noisy labels [8]-[11].            | Accuracy, calibration, ECE, occlusion/pose subset.        |

## 7. Cụ thể hóa đề xuất triển khai từ bản phác thảo

Bản phác thảo EmotionCLIP-ReID trong tài liệu tham chiếu làm rõ hơn cách biến luận điểm semantic anchor thành một pipeline huấn luyện cụ thể. Điểm quan trọng là mô hình không chỉ ghép CLIP với một classifier, mà tổ chức thành hai giai đoạn có vai trò khác nhau. Giai đoạn 1 học các emotion descriptors ở phía văn bản; Giai đoạn 2 giữ cố định các descriptors đó để dẫn hướng image encoder học biểu diễn biểu cảm bền vững hơn trước che khuất và thay đổi góc nhìn.

Ở Giai đoạn 1, đề xuất sử dụng structured prompt thay vì prompt class-name đơn giản. Một prompt có thể có dạng: "a photo of a person expressing [emotion], characterized by [X1][X2]...[XM]". Trong đó

[emotion] là nhãn cảm xúc, còn các token [X] là các token có thể học được nhằm mã hóa các cue tinh vi liên quan tới AU hoặc chuyển động cơ mặt. Image encoder và text encoder của CLIP được giữ cố định; chỉ các token [X] được tối ưu bằng contrastive loss để kéo gần cặp ảnh-prompt đúng và đẩy xa các prompt sai. Kết quả mong muốn là một bộ emotion descriptors có tính phân biệt và giàu thông tin hơn so với tên lớp cảm xúc.

Ở Giai đoạn 2, text encoder và các emotion descriptors đã học được giữ cố định, đóng vai trò như semantic ground truth ở phía ngôn ngữ. Image encoder được tinh chỉnh để ánh xạ cả ảnh bình thường, ảnh bị che khuất và ảnh đa góc nhìn về đúng descriptor tương ứng. Để tránh overfitting và giảm nguy cơ catastrophic forgetting, bản phác thảo đề xuất chèn các adapter gọn nhẹ vào image encoder thay vì cập nhật toàn bộ tham số. Hàm mất mát có thể kết hợp classification loss, contrastive alignment loss và uncertainty loss:  $L_{stage2} = L_{classification} + L_{contrastive} + \lambda * L_{uncertainty}$ .

Thành phần uncertainty được dùng với vai trò hiệu chỉnh độ tin cậy. Với các mẫu mơ hồ hoặc nằm gần ranh giới giữa các lớp cảm xúc, mô hình không nên đưa ra dự đoán sai nhưng quá tự tin. Cách thiết kế này phù hợp với các hướng uncertainty-aware FER: mô hình được khuyến khích tự tin khi bằng chứng rõ, nhưng thể hiện độ bất định cao hơn khi ảnh bị che, pose lệch hoặc nhãn khó phân biệt.

| Đề xuất từ bản phác thảo       | Cách đưa vào EmotionCLIP-ReID                                                          | Ý nghĩa nghiên cứu                                                                           |
|--------------------------------|----------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| Structured emotion prompt      | Dùng mẫu prompt kết hợp nhãn cảm xúc với learnable AU-like tokens [X].                 | Làm text descriptor giàu nghĩa hơn class-name prompt và gần hơn với cơ chế biểu hiện cơ mặt. |
| Frozen CLIP encoders ở Stage 1 | Giữ cố định image/text encoder, chỉ tối ưu các token mô tả.                            | Giữ tri thức nền của CLIP và buộc descriptor học vai trò semantic anchor.                    |
| Fixed text pipeline ở Stage 2  | Giữ cố định text encoder và descriptors đã học; tinh chỉnh image encoder theo anchors. | Tạo chuẩn ngữ nghĩa ổn định để kéo visual features về đúng biểu cảm.                         |
| Adapter-based fine-tuning      | Chèn adapter nhẹ vào visual encoder thay vì full fine-tuning.                          | Giảm overfitting, tiết kiệm tham số và hạn chế catastrophic forgetting.                      |
| Uncertainty calibration loss   | Bổ sung $L_{uncertainty}$ vào objective của Stage 2.                                   | Giảm overconfidence trên ảnh mơ hồ, che khuất hoặc pose lệch.                                |

Về đánh giá, bản phác thảo gợi ý một lộ trình thực nghiệm có tính kiểm chứng rõ hơn. Ngoài so sánh accuracy tổng thể trên các tập in-the-wild như RAF-DB và AffectNet, cần tạo hoặc sử dụng các subset có kiểm soát về che khuất và góc nhìn, ví dụ Occlusion-RAF-DB hoặc Pose-RAF-DB với các ngưỡng pose lớn hơn 30 độ hoặc 45 độ. Các baseline nên gồm CLIP-ReID được điều chỉnh cho phân loại FER, EA-CLIP và UA-FER trên cùng tập dữ liệu để so sánh công bằng. Bên cạnh accuracy, confusion matrix, calibration metrics và độ chính xác trên từng subset nên được báo cáo để chứng minh robustness.

Cuối cùng, phân tích trực quan là một phần quan trọng để bảo vệ luận điểm interpretability. Grad-CAM hoặc attention visualization có thể được dùng để kiểm tra liệu mô hình có tập trung vào các vùng cơ mặt phù hợp như mắt, lông mày và miệng hay không. Nếu emotion descriptors thực sự hoạt động như semantic anchors, kỳ vọng là trong điều kiện che khuất một phần, mô hình vẫn dựa vào các vùng còn quan sát được thay vì chuyển sang shortcut từ nền ảnh hoặc identity.

## 8. Cách xác lập đóng góp nghiên cứu

Đóng góp của đề tài nên được trình bày theo hướng tập trung, tránh tuyên bố giải quyết toàn bộ các vấn đề của FER. Trọng tâm hợp lý là: đề xuất một cơ chế semantic descriptor anchoring cho FER, trong đó

text-side descriptors đóng vai trò ràng buộc ngữ nghĩa để image encoder học biểu diễn biểu cảm ổn định và có khả năng diễn giải hơn.

Để chứng minh đóng góp này, các thí nghiệm ablation cần so sánh class-name prompt, learned emotion descriptor và AU/pseudo-AU descriptor; đồng thời kiểm tra vai trò của fixed anchors, global-local alignment và uncertainty head. Ngoài accuracy tổng thể, nên báo cáo thêm confusion matrix, calibration metrics và kết quả trên các subset có occlusion hoặc pose variation. Cách đánh giá này phù hợp hơn với mục tiêu nghiên cứu về robustness và interpretability.

## 9. Nguồn tham khảo theo IEEE

- [1] Y. Wang et al., "A Survey on Facial Expression Recognition of Static and Dynamic Emotions," arXiv preprint arXiv:2408.15777, 2024. Available: <https://arxiv.org/abs/2408.15777>
- [2] S. Guo et al., "Facial expression recognition under occlusion conditions based on multi-feature cross-attention," Journal of Intelligent & Fuzzy Systems, 2024. Available: <https://doi.org/10.3233/JIFS-233748>
- [3] Y. Cheng and D. Kong, "CSINet: Channel-Spatial Fusion Networks for Asymmetric Facial Expression Recognition," Symmetry, 2024. Available: <https://doi.org/10.3390/sym16040471>
- [4] C. Liu, X. Liu, C. Chen, and K. Zhou, "Deep Global Multiple-Scale and Local Patches Attention Dual-Branch Network for Pose-Invariant Facial Expression Recognition," Computer Modeling in Engineering & Sciences, 2024. Available: <https://doi.org/10.32604/cmes.2023.031040>
- [5] O. Ikne, B. Allaert, I. M. Bilasco, and H. Wannous, "eMotion-GAN: A Motion-based GAN for Photorealistic and Facial Expression Preserving Frontal View Synthesis," arXiv preprint arXiv:2404.09940, 2024. Available: <https://arxiv.org/abs/2404.09940>
- [6] J. Chen and S. Dey, "Graph-Based Multi-Modal Multi-View Fusion for Facial Action Unit Recognition," IEEE Access, 2024. Available: <https://doi.org/10.1109/ACCESS.2024.3401168>
- [7] H. Liu et al., "Norface: Improving Facial Expression Analysis by Identity Normalization," Proc. European Conf. Computer Vision (ECCV), 2024. Available: [https://www.ecva.net/papers/eccv\\_2024/papers\\_ECCV/html/7224\\_ECCV\\_2024\\_paper.php](https://www.ecva.net/papers/eccv_2024/papers_ECCV/html/7224_ECCV_2024_paper.php)
- [8] Y. Liu, X. Zhang, J. Kauttonen, and G. Zhao, "Uncertain Facial Expression Recognition via Multi-task Assisted Correction," arXiv preprint, 2022.
- [9] Zhang et al., "MAN: Mining Ambiguity and Noise for Facial Expression Recognition in the Wild," Pattern Recognition Letters, 2022.
- [10] N. Le et al., "Uncertainty-Aware Label Distribution Learning for Facial Expression Recognition," Proc. IEEE/CVF Winter Conf. Applications of Computer Vision (WACV), 2023.
- [11] D. Li, W. Xiong, T. Luo, and L. Zhang, "3WAUS: A Novel Three-Way Adaptive Uncertainty-Suppressing Model for Facial Expression Recognition," Information Sciences, 2024.
- [12] R. Zhang et al., "Tip-Adapter: Training-free Adaption of CLIP for Few-shot Classification," Proc. European Conf. Computer Vision (ECCV), 2022.
- [13] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, "Learning to Prompt for Vision-Language Models," International Journal of Computer Vision, 2022.
- [14] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, "Conditional Prompt Learning for Vision-Language Models," Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2022.
- [15] M. U. Khattak et al., "MaPLe: Multi-Modal Prompt Learning," Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2023.
- [16] H. Li, H. Niu, Z. Zhu, and F. Zhao, "CLIPER: A Unified Vision-Language Framework for In-the-Wild Facial Expression Recognition," arXiv preprint, 2023.
- [17] Z. Zhao and I. Patras, "Prompting Visual-Language Models for Dynamic Facial Expression Recognition," Proc. British Machine Vision Conf. (BMVC), 2023.
- [18] H. Chen et al., "FineCLIPER: Multi-modal Fine-grained CLIP for Dynamic Facial Expression Recognition with AdaptERs," arXiv preprint, 2024.
- [19] J. Huan, M. Li, and H. Zhou, "Emotion-aware adaptation of CLIP model for facial expression recognition," Artificial Intelligence Review, 2026.
- [20] S. Li, L. Sun, and Q. Li, "CLIP-ReID: Exploiting Vision-Language Model for Image Re-Identification without Concrete Text Labels," arXiv preprint, 2022.
- [21] S. Yang et al., "A Pedestrian is Worth One Prompt: Towards Language Guidance Person Re-Identification," Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2024.
- [22] Q. Han et al., "CLIP-SCGI: Synthesized Caption-Guided Inversion for Person Re-Identification," arXiv preprint, 2024.
- [23] X. Yu, N. Dong, L. Zhu, H. Peng, and D. Tao, "CLIP-Driven Semantic Discovery Network for Visible-Infrared Person Re-Identification," IEEE Transactions on Multimedia, 2025.
- [24] S. Liu et al., "MER-CLIP: AU-Guided Vision-Language Alignment for Micro-Expression Recognition," arXiv preprint, 2025.
- [25] X. Ge et al., "Towards End-to-End Explainable Facial Action Unit Recognition via Vision-Language Joint Learning," arXiv preprint, 2024.
- [26] K. Yuan et al., "AUFormer: Vision Transformers are Parameter-Efficient Facial Action Unit Detectors," Proc. European Conf. Computer Vision (ECCV), 2024.
- [27] Z. Shang et al., "Learning Contrastive Feature Representations for Facial Action Unit Detection," Pattern Recognition, 2025.