

# Related Work Logic for EmotionCLIP-ReID

*Viết lại mạch nghiên cứu từ FER hiện tại tới mô hình đề xuất, trích dẫn theo IEEE*

## 1. Luận điểm trung tâm

Facial Expression Recognition (FER) hiện nay không còn là bài toán nhận dạng bảy nhãn cảm xúc trong điều kiện sạch. Trong môi trường in-the-wild, biểu cảm thường bị che khuất, lệch góc nhìn, chịu nhiễu identity/background/illumination, và có nhãn mơ hồ hoặc compound emotion [1]. Vì vậy, một mô hình FER tốt không chỉ cần tăng accuracy, mà còn phải học được biểu diễn biểu cảm ổn định, có thể giải thích, và ít phụ thuộc vào shortcut thị giác.

Luận điểm của EmotionCLIP-ReID nên được viết theo chuỗi nhân quả: vì FER in-the-wild thiếu tín hiệu ổn định, các hướng hiện tại dùng attention, local patches, normalization, multi-view/multimodal fusion và uncertainty learning để tăng robustness [2]-[11]. Tuy nhiên, nhiều hướng vẫn học visual feature thuần túy hoặc dùng class-name prompt thô. Do đó, project đề xuất mượn cơ chế text-anchor hai giai đoạn của CLIP-ReID [20], nhưng thay ID token bằng emotion/AU semantic descriptors có nghĩa để dẫn hướng image encoder học biểu diễn biểu cảm.

## 2. Từ vấn đề FER hiện tại tới nhu cầu semantic anchor

Khó khăn đầu tiên là occlusion. Khi khẩu trang, kính, tóc, tay hoặc vật thể che vùng miệng/mắt, các AU quan trọng như lip corner puller, cheek raiser, eye closure hoặc brow lowerer có thể biến mất khỏi ảnh. Các mô hình occlusion-aware gần đây thường dùng multi-branch feature, cross-attention hoặc channel-spatial fusion để giảm ảnh hưởng vùng bị che [2], [3]. Các kỹ thuật này cải thiện robustness, nhưng bản thân local branch không đảm bảo học đúng ý nghĩa cơ mặt nếu thiếu semantic prior.

Khó khăn thứ hai là pose, đa góc nhìn và self-occlusion. Khi mặt xoay khỏi frontal view, một phần mắt/miệng bị mất hoặc bị biến dạng do phép chiếu 3D sang 2D. Các hướng pose-invariant FER dùng local patch attention, multi-scale attention hoặc frontalization để giữ lại thông tin biểu cảm [4], [5]. Một số hướng AU recognition còn dùng multi-view/multimodal fusion để bù thông tin giữa các góc nhìn [6]. Tuy nhiên, frontalization có nguy cơ làm biến dạng biểu cảm, còn multi-view fusion làm tăng yêu cầu dữ liệu và thiết bị.

Khó khăn thứ ba là nhiễu identity, background, illumination và domain shift. Norface cho thấy việc chuẩn hóa identity, pose và background có thể giúp mô hình tập trung hơn vào yếu tố liên quan biểu cảm, đồng thời cải thiện AU detection, AU intensity và FER [7]. Dù vậy, normalization là một pipeline phụ và có thể tăng độ phức tạp. Một hướng nhẹ hơn là giữ ảnh đầu vào tự nhiên, nhưng ràng buộc biểu diễn bằng semantic descriptors để mô hình bớt phụ thuộc vào identity/background shortcut.

Khó khăn cuối cùng là label ambiguity. Cùng một khuôn mặt có thể được gán nhiều nhãn hợp lý, đặc biệt với biểu cảm nhẹ, compound emotion hoặc ảnh chất lượng thấp. Các hướng uncertainty-aware FER, label distribution learning và auxiliary AU graph cho thấy softmax một-nhãn dễ overconfident trong các trường hợp mơ hồ [8]-[11]. Điều này gợi ý rằng uncertainty nên là module hiệu chỉnh/calibration sau khi descriptor alignment đã ổn, thay vì là đóng góp duy nhất của mô hình.

| Vấn đề FER                             | Hướng xử lý hiện tại                                                   | Giới hạn còn lại                                                       | Hàm ý cho EmotionCLIP-ReID                                                                      |
|----------------------------------------|------------------------------------------------------------------------|------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| Occlusion vùng mắt/miệng               | Multi-branch feature, cross-attention, channel-spatial fusion [2], [3] | Local feature vẫn có thể học cue thuần visual, thiếu diễn giải AU.     | Gắn local visual cue với emotion/AU descriptors để biết vùng còn quan sát được mang ý nghĩa gì. |
| Pose lệch, đa góc nhìn, self-occlusion | Pose-invariant attention, frontalization, multi-view fusion [4]-[6]    | Frontalization/multi-view tăng chi phí và có nguy cơ làm méo biểu cảm. | Dùng global-local image-text alignment để giữ cue biểu cảm theo cả toàn mặt và vùng cơ mặt.     |
| Identity/background/domain shift       | Identity normalization, augmentation, domain generalization [7]        | Pipeline phụ có thể làm mô hình phức tạp và phụ thuộc preprocessing.   | Dùng text-side anchors để giảm shortcut identity/background trong visual encoder.               |
| Label ambiguity và overconfidence      | Label distribution, uncertainty/evidence learning, AU graph [8]-[11]   | Calibration không tự tạo semantic representation.                      | Đặt uncertainty như head phụ sau khi semantic alignment đã hình thành.                          |

### 3. Vì sao CLIP/VLM là cầu nối hợp lý

Vision-language models (VLMs) cung cấp một không gian embedding nơi ảnh và ngôn ngữ có thể được căn chỉnh. Các phương pháp như Tip-Adapter, CoOp, CoCoOp và MaPLe cho thấy có thể thích nghi CLIP bằng adapter hoặc prompt learning thay vì huấn luyện lại toàn bộ mô hình [12]-[15]. Điểm quan trọng đối với FER là text prompt không chỉ đóng vai trò nhãn lớp, mà có thể mã hóa mô tả giàu nghĩa về chuyển động cơ mặt.

Trong FER/DFER, CLIPER, DFER-CLIP, FineCLIPER và EA-CLIP đã chứng minh rằng mô tả văn bản, temporal modeling và adapter có thể cải thiện nhận dạng biểu cảm [16]-[19]. Tuy nhiên, nếu chỉ dùng prompt kiểu "a happy face" hoặc thêm adapter vào visual encoder, đóng góp dễ bị xem là prompt tuning thông thường. Khoảng trống cần nhấn mạnh là descriptor phải cụ thể hơn class name: nó cần mô tả AU, vùng mặt, cường độ và quan hệ local-global.

### 4. Từ CLIP-ReID tới EmotionCLIP-ReID

CLIP-ReID hữu ích vì không cần concrete text labels nhưng vẫn dùng text feature làm anchor cho image encoder qua hai giai đoạn [20]. Trong ReID, các token được học theo từng identity giúp phân biệt người, nhưng chúng không nhất thiết có ý nghĩa ngôn ngữ. Các hướng ReID gần đây như Pedestrian Prompt, CLIP-SCGI và CLIP-driven semantic discovery tiếp tục cho thấy language guidance có thể giúp mô hình học đặc trưng phân biệt hơn [21]-[23].

Khi chuyển sang FER, không nên bê nguyên ID-token logic sang biểu cảm. Identity token phù hợp cho ReID vì mục tiêu là phân biệt người; còn FER cần phân biệt trạng thái cơ mặt có tính mềm, mơ hồ và phụ thuộc ngữ cảnh. Vì vậy, điểm kế thừa là cơ chế anchor hai giai đoạn, còn điểm thay đổi là đơn vị anchor: từ ID-specific tokens sang emotion/AU semantic descriptors.

### 5. AU/FACS làm descriptor có thể diễn giải

Action Units (AU) và Facial Action Coding System (FACS) là lớp trung gian tự nhiên giữa ảnh mặt và nhãn cảm xúc. Các công trình như MER-CLIP, VL-FAU, AUFormer và AUNCE cho thấy AU có thể được dùng để căn chỉnh vision-language, phát hiện hành động cơ mặt, hoặc học biểu diễn tương phản cho AU

detection [24]-[27]. Vì vậy, descriptor không nên chỉ là "happy", "sad" hoặc "angry", mà nên có dạng mô tả: raised cheeks, lip corner puller, brow lowerer, eye closure, mouth opening, v.v.

Dù vậy, AU không nên được viết như giả định bắt buộc cho mọi dataset. Nhiều tập FER không có AU label, AU annotation có thể nhiều, và biểu cảm phức hợp không ánh xạ một-một sang AU. Cách viết an toàn hơn là xem AU/FACS như semantic prior có điều kiện: v1 dùng emotion descriptors; v2 hoặc ablation dùng AU/pseudo-AU descriptors; kết quả cần so sánh class prompt, learned descriptor và AU descriptor.

## 6. Mô hình đề xuất theo mạch logic

Từ các phân tích trên, EmotionCLIP-ReID có thể được mô tả như một mô hình image-text FER lấy CLIP-ReID làm khung anchor, nhưng thiết kế lại text side cho biểu cảm. Stage 1 học EmotionPromptLerner để sinh emotion/AU descriptors bằng CLIP text encoder. Sau Stage 1, descriptor embeddings được cố định như semantic anchors. Stage 2 dùng các anchors này để dẫn hướng image encoder học biểu diễn biểu cảm thông qua global image-text alignment và local/AU-aware alignment.

Image encoder nên có expression-aware adapters hoặc lightweight tuning để tránh phá hỏng tri thức nền của CLIP. Global feature giữ ngữ cảnh toàn mặt, trong khi local feature hoặc AU-aware tokens tập trung vào vùng mắt, mũi, miệng và lông mày. Classifier head dự đoán emotion label; uncertainty/evidence head có thể bổ sung để giảm overconfidence trong trường hợp ảnh bị che, pose lệch hoặc label mơ hồ. Như vậy, mô hình không chỉ là "CLIP + classifier", mà là một pipeline descriptor-anchor có giải thích được.

| Thành phần mô hình                      | Vai trò                                                    | Động cơ từ related work                                                    | Cần chứng minh bằng ablation                                      |
|-----------------------------------------|------------------------------------------------------------|----------------------------------------------------------------------------|-------------------------------------------------------------------|
| EmotionPromptLerner + CLIP text encoder | Sinh descriptor embeddings cho emotion/AU.                 | VLM/prompt learning cho phép học prompt thích nghi downstream [12]-[15].   | Class-name prompt vs learned emotion descriptor vs AU descriptor. |
| Fixed semantic anchors                  | Ổn định hướng học visual encoder sau Stage 1.              | CLIP-ReID dùng text feature làm anchor cho image encoder [20].             | Không anchor vs trainable anchor vs fixed anchor.                 |
| Expression-aware image encoder/adapters | Thích nghi visual feature cho FER nhưng giữ tri thức CLIP. | CLIPER/FineCLIPER/EA-CLIP cho thấy adapter hữu ích cho FER/DFER [16]-[19]. | Frozen CLIP vs adapter vs full fine-tuning.                       |
| Global-local image-text alignment       | Gắn toàn mặt và vùng AU với descriptor tương ứng.          | Occlusion/pose FER cần local attention và fusion [2]-[6].                  | Global only vs local only vs global-local.                        |
| Uncertainty/evidence head               | Giảm overconfidence trong ảnh mơ hồ hoặc bị nhiễu.         | Uncertainty-aware FER xử lý ambiguity và noisy labels [8]-[11].            | Accuracy, calibration, ECE, occlusion/pose subset.                |

## 7. Cách viết contribution cho chặt

- Không viết rằng project giải quyết mọi vấn đề FER. Nên viết: project tập trung vào semantic anchoring để làm biểu diễn FER ổn định hơn trước occlusion, pose và ambiguity.
- Không đặt AU label như điều kiện bắt buộc. Nên viết: AU/FACS là prior có điều kiện; nếu dataset thiếu AU, dùng pseudo-AU hoặc descriptor do prompt learner học.

- Không để uncertainty lẫn át đóng góp chính. Nên viết: uncertainty là module calibration phụ, dùng sau khi baseline descriptor-anchor đã được chứng minh.
- Ablation bắt buộc: class-name prompt, learned emotion descriptor, AU descriptor, fixed/trainable anchor, global/local alignment, và occlusion/pose robustness subset.

## 8. Nguồn tham khảo theo IEEE

- [1] Y. Wang et al., "A Survey on Facial Expression Recognition of Static and Dynamic Emotions," arXiv preprint arXiv:2408.15777, 2024. Available: <https://arxiv.org/abs/2408.15777>
- [2] S. Guo et al., "Facial expression recognition under occlusion conditions based on multi-feature cross-attention," Journal of Intelligent & Fuzzy Systems, 2024. Available: <https://doi.org/10.3233/JIFS-233748>
- [3] Y. Cheng and D. Kong, "CSINet: Channel-Spatial Fusion Networks for Asymmetric Facial Expression Recognition," Symmetry, 2024. Available: <https://doi.org/10.3390/sym16040471>
- [4] C. Liu, X. Liu, C. Chen, and K. Zhou, "Deep Global Multiple-Scale and Local Patches Attention Dual-Branch Network for Pose-Invariant Facial Expression Recognition," Computer Modeling in Engineering & Sciences, 2024. Available: <https://doi.org/10.32604/cmes.2023.031040>
- [5] O. Ikne, B. Allaert, I. M. Bilasco, and H. Wannous, "eMotion-GAN: A Motion-based GAN for Photorealistic and Facial Expression Preserving Frontal View Synthesis," arXiv preprint arXiv:2404.09940, 2024. Available: <https://arxiv.org/abs/2404.09940>
- [6] J. Chen and S. Dey, "Graph-Based Multi-Modal Multi-View Fusion for Facial Action Unit Recognition," IEEE Access, 2024. Available: <https://doi.org/10.1109/ACCESS.2024.3401168>
- [7] H. Liu et al., "Norface: Improving Facial Expression Analysis by Identity Normalization," Proc. European Conf. Computer Vision (ECCV), 2024. Available: [https://www.ecva.net/papers/eccv\\_2024/papers\\_ECCV/html/7224\\_ECCV\\_2024\\_paper.php](https://www.ecva.net/papers/eccv_2024/papers_ECCV/html/7224_ECCV_2024_paper.php)
- [8] Y. Liu, X. Zhang, J. Kauttonen, and G. Zhao, "Uncertain Facial Expression Recognition via Multi-task Assisted Correction," arXiv preprint, 2022.
- [9] Zhang et al., "MAN: Mining Ambiguity and Noise for Facial Expression Recognition in the Wild," Pattern Recognition Letters, 2022.
- [10] N. Le et al., "Uncertainty-Aware Label Distribution Learning for Facial Expression Recognition," Proc. IEEE/CVF Winter Conf. Applications of Computer Vision (WACV), 2023.
- [11] D. Li, W. Xiong, T. Luo, and L. Zhang, "3WAUS: A Novel Three-Way Adaptive Uncertainty-Suppressing Model for Facial Expression Recognition," Information Sciences, 2024.
- [12] R. Zhang et al., "Tip-Adapter: Training-free Adaption of CLIP for Few-shot Classification," Proc. European Conf. Computer Vision (ECCV), 2022.
- [13] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, "Learning to Prompt for Vision-Language Models," International Journal of Computer Vision, 2022.
- [14] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, "Conditional Prompt Learning for Vision-Language Models," Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2022.
- [15] M. U. Khattak et al., "MaPLe: Multi-Modal Prompt Learning," Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2023.
- [16] H. Li, H. Niu, Z. Zhu, and F. Zhao, "CLIPER: A Unified Vision-Language Framework for In-the-Wild Facial Expression Recognition," arXiv preprint, 2023.
- [17] Z. Zhao and I. Patras, "Prompting Visual-Language Models for Dynamic Facial Expression Recognition," Proc. British Machine Vision Conf. (BMVC), 2023.
- [18] H. Chen et al., "FineCLIPER: Multi-modal Fine-grained CLIP for Dynamic Facial Expression Recognition with AdaptERs," arXiv preprint, 2024.
- [19] J. Huan, M. Li, and H. Zhou, "Emotion-aware adaptation of CLIP model for facial expression recognition," Artificial Intelligence Review, 2026.
- [20] S. Li, L. Sun, and Q. Li, "CLIP-ReID: Exploiting Vision-Language Model for Image Re-Identification without Concrete Text Labels," arXiv preprint, 2022.
- [21] S. Yang et al., "A Pedestrian is Worth One Prompt: Towards Language Guidance Person Re-Identification," Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2024.
- [22] Q. Han et al., "CLIP-SCGI: Synthesized Caption-Guided Inversion for Person Re-Identification," arXiv preprint, 2024.
- [23] X. Yu, N. Dong, L. Zhu, H. Peng, and D. Tao, "CLIP-Driven Semantic Discovery Network for Visible-Infrared Person Re-Identification," IEEE Transactions on Multimedia, 2025.

- [24] S. Liu et al., "MER-CLIP: AU-Guided Vision-Language Alignment for Micro-Expression Recognition," arXiv preprint, 2025.
- [25] X. Ge et al., "Towards End-to-End Explainable Facial Action Unit Recognition via Vision-Language Joint Learning," arXiv preprint, 2024.
- [26] K. Yuan et al., "AUFormer: Vision Transformers are Parameter-Efficient Facial Action Unit Detectors," Proc. European Conf. Computer Vision (ECCV), 2024.
- [27] Z. Shang et al., "Learning Contrastive Feature Representations for Facial Action Unit Detection," Pattern Recognition, 2025.